



Forensic WhisperDeskZH

User Manual

[Abstract](#)

Beschreibung und Anleitung für die Nutzung des Forensic WhisperDeskZH

ForMaLTeC

1. Übersicht	3
Wichtigste Merkmale:	3
Voraussetzungen	3
Minimale Systemanforderungen	3
Empfohlene Systemanforderungen	3
2. Wichtige Begriffe & Symbole	4
3. Installation	5
Schritt für Schritt	5
4. Erste Schritte	6
Erster Start	6
Einfache Transkription	6
5. User Interface	7
Steuerelemente	7
Zuhören Starten/Beenden	7
Diktat Starten/Beenden	7
Mikrofonauswahl	8
Modelauswahl	8
Sprachauswahl	8
Modelleinstellungen	9
Reset-Knopf	9
6. Sprachbefehle & Satzzeichen	10
Sprachbefehle im Zuhörer Modus	10
Sprachbefehle im Diktatmodus	10
Standartbefehle	10
Benutzerdefinierte Befehle	10
Bearbeiten von Sprachbefehlen.	10
Wo finde ich die «keywords.xml» Datei?	10
Wie ist die Datei aufgebaut?	11
Wie kann ich die Datei bearbeiten?	11
Einschränkungen:	11
7. Troubleshooting	12
Ich kann die Menüleiste des Add-Ins nicht sehen.	12
Nach dem Starten der Transkription, stürzt Word ab.	12
Word stürzt ab, kaum wurde auf den Diktat Knopf gedrückt.	12
Es dauert eine Weile, und der Computer fährt zu Höchstleistungen auf, bevor Word abstürzt.	12
Die Transkription ist fehlerhaft	12
Der eingefügte Text ist in der falschen Sprache.	12
Es werden nur Interjektionen, Satzzeichen und Kauderwelsch eingefügt.	13
Jeweils am Anfang oder Ende eines eingefügten Textblocks ist die Transkription fehlerhaft	13
8. Impressum	14

1. Übersicht

Der Forensic WhisperDeskZH ist ein Add-In für Microsoft Word, das die Transkription von Sprache in Text in Echtzeit ermöglicht. Es verwendet fortschrittliche KI-Modelle (Whisper), um Ihre gesprochenen Worte direkt als Text in Word-Dokumenten einzufügen. Dabei funktioniert die Transkription ohne Verbindung zum Internet. Die KI-Modelle werden lokal ausgeführt und keine Audiodaten dauerhaft gespeichert. Somit wird eine sichere Transkription möglich.

Wichtigste Merkmale:

- **Echtzeit-Transkription** direkt in Word Dokumente
- **Mehrsprachige Unterstützung**
- **Verschiedene KI-Modelloptionen** für optimale Leistung
- **Komplett Internet unabhängige, lokale Transkription**

Voraussetzungen

Minimale Systemanforderungen

Betriebssystem: Windows 10 oder höher

Microsoft Word: 2016 oder höher

Arbeitsspeicher: 8GB RAM

Speicherplatz: 8 GB freier Speicherplatz

GPU: nicht notwendig (aber empfohlen)

Audio: Funktionierendes Mikrofon oder Audio-Eingabegerät

Empfohlene Systemanforderungen

Betriebssystem: Windows 10 oder höher

Microsoft Word: 2016 oder höher

Arbeitsspeicher: 16 GB RAM

Speicherplatz: 16 GB freier Speicherplatz

GPU: Nvidia GPU mit CUDA-Kernen und 8 GB GPU Speicher, RTX 2000 ADA-Generation oder neuer.

Audio: Mikrofon mit gutem Filter für Umgebungsgeräusche (vorzugsweise analoger Filter).

2. Wichtige Begriffe & Symbole

Diktatmodus: Im Diktatmodus, transkribiert das Add-in sämtliche vom Mikrofon aufgenommene Sprache und fügt den transkribierten Text direkt in das geöffnete Word Dokument an der Stelle des Cursors ein.

Zuhörmodus: Der Zuhörmodus bezeichnet den Modus, in welchem das Add-in bereits mithört, den transkribierten Text aber noch nicht in das geöffnete Word Dokument einfügt. Erst wenn das Add-in Durch den Sprachbefehl «Diktat Starten» in den Diktatmodus versetzt wird, wird Text im Dokument eingefügt.

Minimal Audio Chunk Size: Für die Echtzeit Transkription, muss die Audioaufnahme kurz unterbrochen und ausgelesen werden. Die Minimal Audio Chunk Size bestimmt die minimale Zeitspanne in Sekunden, welche vergehen muss, dass das Add-in eine Transkription startet. Kürzere Werte führen zu häufigerer und schneller Transkription ins Word Dokument, im Gegenzug sinkt aber die Genauigkeit. Mit grösseren Werten wird die Transkription weniger häufig aktualisiert, die Genauigkeit nimmt aber zu. Bei eher schwächeren Rechnern empfiehlt es sich eine eher lange Chunk Size zu wählen. (15-20 Sekunden).

Silence Threshold: Um die Genauigkeit der Transkription zu erhöhen versucht das Add-in Pausen zwischen Wörtern und Sätzen zu erkennen. Dies soll verhindern, dass Worte abgeschnitten und somit fehlerhaft transkribiert werden. Der Silence Threshold bestimmt, wie lange es Still sein muss, dass das Plugin von einer Pause zwischen Worten ausgeht.

3. Installation

Schritt für Schritt

1. Die neusten Versionen des Add-Ins finden sie unter: [Releases](#) · [ForMaLTec/Forensic-WhisperDeskZH-Word-Add-In](#)
2. **Wählen sie den Gewünschten Release** aus der Release Liste.
3. **Laden Sie ALLE Teile herunter**, welche nach folgendem Muster benannt sind:
VSTO-Addin-Package-[Versions-Nummer].zip.001, .002 usw., der Source-Code wird für die Installation nicht benötigt.
4. **Speichern Sie ALLE Teile im selben Verzeichnis/Ordner** auf Ihrem Computer.
5. **Entpacken Sie die Dateien mit 7-Zip** – klicken Sie mit der rechten Maustaste auf die Datei .001 und entpacken Sie sie lokal auf ihren Rechner.
6. **Öffnen Sie den entpackten Ordner.**
7. **Führen Sie „setup.exe“** aus den extrahierten Dateien als Administrator** aus.
8. **Folgen sie den Anweisungen des Installers**

WICHTIG: die setup.exe Datei nicht aus dem Ordner herausziehen. Sie muss neben der vsto Datei und dem ApplicationFiles Ordner ausgeführt werden.

Ist die Installation erfolgreich abgeschlossen sollte bei einem Neustart von Word nun die Menu Leiste „Add-Ins“ hinzugefügt worden sein. Ist diese nicht sichtbar ist die Installation fehlgeschlagen.

4. Erste Schritte

Erster Start


1. Stellen Sie sicher, dass ein Mikrofon an ihrem PC angeschlossen ist und funktioniert.
2. Öffnen Sie Microsoft Word wie gewohnt.
3. Klicken Sie auf die Registerkarte „Add-Ins“ in der Multifunktionsleiste
4. Warten Sie, bis das Add-In initialisiert ist (dies kann beim ersten Start einige Augenblicke dauern)

Einfache Transkription

1. **Öffnen Sie ein Word-Dokument** oder erstellen Sie ein neues Dokument
2. **Positionieren Sie den Cursor** an der Stelle, an der der transkribierte Text erscheinen soll
3. **Wählen Sie Ihr Mikrofon** aus der Dropdown-Liste
4. Klicken Sie auf „**Diktat starten**“.
5. **Beginnen Sie zu sprechen** - Ihre Worte werden nach einer Pause im Dokument erscheinen
6. **Klick „Transkription stoppen“**, wenn Sie fertig sind, um die Transkription zu beenden.


5. User Interface

Steuerelemente



Die Multifunktionsleiste des Add-ins enthält die folgenden Steuerelemente:


Zuhören Starten/Beenden



Mit dem Knopf «Zuhören Starten» kann das Add-In in einen Zuhörer Modus versetzt werden. Befindet sich das Add-In in diesem Zuhörer Modus, transkribiert das Add-In sämtliche über das ausgewählte Mikrofon aufgezeichnete Sprache. Das Resultat der Transkription wird aber nicht in das aktive Word Dokument eingefügt. Erst wenn das Plugin den Sprachbefehl «**Diktat Starten**» wahrnimmt, beginnt das Einfügen des transkribierten Textes. Um das Einfügen zu beenden, muss der Sprachbefehl «**Diktat Beenden**» genutzt werden. Wird der Zuhörer Modus nicht beendet, so kann jederzeit wieder ein Diktat begonnen werden.

- **Zuhören Starten:** Der Zuhörmodus wird aktiviert.
- **Zuhören Beenden:** Der Zuhörmodus wird wieder beendet.
- Der Status ändert sich je nach aktuellem Transkriptionsstatus


Diktat Starten/Beenden



Mit dem Diktat Starten/Beenden Knopf lässt sich das Add-in direkt in den Diktatmodus versetzen. In diesem Diktat Modus wird sämtliche, über das ausgewählte Mikrofon aufgezeichnete Sprache transkribiert und die Transkription wird direkt beim Cursor in das Word Dokument eingefügt.


- **Diktieren starten:** Beginnt die Spracherkennung in Echtzeit.
- **Diktieren stoppen:** Beendet die Transkription und speichert die Einstellungen
- Der Status ändert sich je nach aktuellem Transkriptionsstatus

Mikrofonauswahl



- Dropdown-Liste der verfügbaren Audio-Eingabegeräte
- Wählen Sie Ihr bevorzugtes Mikrofon, bevor Sie mit der Transkription beginnen
- Änderungen werden sofort übernommen

Modelauswahl




Wählen Sie je nach Bedarf aus verschiedenen KI-Modellen:

- **Tiny:** Sehr schnell, aber sehr ungenau.
- **Small:** Bessere Genauigkeit, moderate Geschwindigkeit.
- **Base:** Gutes Gleichgewicht zwischen Geschwindigkeit und Genauigkeit.
- **Medium:** Hohe Genauigkeit, langsamere Verarbeitung
- **Large V3:** Höchste Genauigkeit, langsamste Verarbeitung
- **Large V3 Turbo:** Beste Genauigkeit bei verbesserter Geschwindigkeit

WICHTIG: Die Modelle «Large V3» und «Large V3 Turbo» benötigen viele Ressourcen! Es sollten die empfohlenen Systemanforderungen erfüllt sein.

Sprachauswahl



Es besteht die Möglichkeit zwischen verschiedenen Sprachen auszuwählen.

Aktuell sind folgende Sprachen verfügbar:

- Deutsch
- Englisch
- Französisch
- Italienisch
- Spanisch

Modeleinstellungen

Der Forensic WhisperDeskZH ermöglicht das Anpassen zweier Einstellungen, welche direkten Einfluss auf die Echtzeittranskription nehmen.

Dauer der Stille zwischen Wörtern (0-1000 Millisekunden)

Der Wert „Dauer der Stille zwischen Wörtern definiert die Anzahl Millisekunden, welche vom Add-in als Pause zwischen Wörtern wahrgenommen werden. Dies hat direkten Einfluss darauf, wo im Satz das Add-in die Audioaufnahme transkribiert.


Für langsame Sprecher sollte dieser Wert erhöht werden, spricht man eher schnell kann er reduziert werden.

Minimale Dauer von Audioblöcken (1-30 Sekunden)

Die Minimale Dauer von Audioblöcken ist die untere Grenze für die Häufigkeit in der Audioblöcke transkribiert werden. Ein tieferer Wert steigert die Kadenz in welcher neu Transkribierter Text eingefügt wird, ein hoher Wert senkt diese.

ACHTUNG: Mit höherer Kadenz sinkt die Genauigkeit der Transkription!

Reset-Knopf



Mit dem Reset-Knopf lassen sich die erweiterten Einstellungen einfach zurücksetzen. Durch ein Drücken auf diesen Knopf werden folgende Einstellungen zurückgesetzt:

- Dauer der Stille zwischen Wörtern wird auf 500 Millisekunden gesetzt.
- Minimale Dauer von Audioblöcken wird auf 5 Sekunden gesetzt.

ACHTUNG: Vorherige Einstellungen können nicht wieder hergestellt werden.

6. Sprachbefehle & Satzzeichen

Sprachbefehle im Zuhörer Modus

- **Diktat Starten:** Das Add-in wechselt vom Zuhör- in den Diktatmodus
- **Diktat Beenden:** Das Add-in wechselt vom Diktatmodus in den Zuhörmodus

ACHTUNG: Beide Befehle funktionieren nur wenn der Zuhörmodus über den «Zuhörmodus Starten/Beenden» Knopf aktiviert wurde.

Sprachbefehle im Diktatmodus

Das System erkennt Sprachbefehle für Interpunktion und Formatierung. Entdeckt das Add-in eines der folgenden Worte im transkribierten Text, so wird diese durch das entsprechende Satzzeichen ersetzt.

Standartbefehle

- „Punkt“ → .
- „Komma“ → ,
- „Ausrufezeichen“ → !
- „Fragezeichen“ → ?
- „Doppelpunkt“ → :
- „Semikolon“ → ;
- „Bindestrich“ → -
- „Abstand“ → [Neuer Absatz]

Benutzerdefinierte Befehle

Sie können benutzerdefinierte Sprachbefehle hinzufügen, indem Sie die Datei Keywords.xml ändern.

WICHTIG: Das Add-in kann nur ersetzen. Sprachbefehle welche Word selbst kontrollieren (z.B. «Dokument speichern») sind aktuell nicht möglich.

Bearbeiten von Sprachbefehlen.

Die Sprachbefehle für das Add-In sind in einer XML-Datei namens Keywords abgelegt.

Diese Datei kann von jedem User, spezifisch für seine Maschine bearbeitet werden. Dabei muss aber beachtet werden, das aktuell nur Textbezogene Sprachbefehle hinzugefügt werden können.

Wo finde ich die «keywords.xml» Datei?

Die keywords.xml Datei wird beim ersten Installieren automatisch in den lokalen App Daten des ForensicWhisperDeskZH angelegt.

1. Explorer öffnen

2. In der Dateipfadleiste «%localappdata%» eingeben und den Ordner «ForensicWhisperDeskZH» öffnen und mit Enter bestätigen.

Wie ist die Datei aufgebaut?

Die Datei ist ein strukturiertes XML-File. «**KeywordReplacements**» ist das Element, welches die Liste der Sprachbefehle darstellt. Einzelne Sprachbefehle werden als «**Replacement**» Element gespeichert. Ein solches Element besteht aus zwei Subelementen, «**Word**» & «**Symbol**». Dabei stellt Word den Befehl und Symbol den einzufügenden Text dar. Beispiel: **<KeywordReplacements>**

```
<Replacement>
  <Word>Punkt</Word>
  <Symbol>.</Symbol>
</Replacement>
<Replacement>
  <Word>Komma</Word>
  <Symbol>,</Symbol>
</Replacement>
<Replacement>
  <Word>Ausrufezeichen</Word>
  <Symbol>!</Symbol>
</Replacement>
</KeywordReplacements>
```

Wie kann ich die Datei bearbeiten?

1. Rechtsklick auf keywords.xml und im Menu «öffnen mit...» auswählen.
2. Die Datei mit einem Texteditor bearbeiten (Notepad++, Notepad, etc.)

Beim Bearbeiten der Datei ist darauf zu achten das die Grundlegende XML-Struktur nicht verändert wird. Am besten wird ein **ganzer Replacement Block** (von **<Replacement>** bis und mit **</Replacement>**) **kopiert**, und oberhalb von **</KeywordReplacements>** wieder eingefügt. Danach kann das **Wort zwischen** **<Word>** & **</Word>** durch den gewünschten Befehl und der **Text zwischen** **<Symbol>** und **</Symbol>** durch den einzufügenden Text ersetzt werden.

Einschränkungen:

- Nur Textbezogene Befehle
- Befehle sollten aus einem einzigen Wort bestehen. Befehle mit mehreren Wörtern sind möglich, aber sehr Fehleranfällig, und können zu fehlerhaften Transkriptionen führen.

7. Troubleshooting

Ich kann die Menüleiste des Add-Ins nicht sehen.

1. Vergewissere dich, dass dein Computer die Mindestanforderungen erfüllt
2. Wahrscheinlich ist bei der Installation ein Fehler aufgetreten.
3. Versuche das Add-In nochmals zu installieren.
 - Dazu zuerst in den Einstellungen unter “Programme hinzufügen/entfernen” das **ForensicWhisperDeskZH** Add-In entfernen.
 - Die setup.exe Datei nochmals ausführen.

Taucht das Add-in immer noch nicht in der Menüleiste auf, Installiere die “[Visual Studio 2010 Tools for Office Runtime](#)” sowie die [.NET Framework 4.8 Runtime](#) (wichtig Runtime und nicht SDK installieren.). Installiere das Add-In nochmals neu, sollte das Problem noch nicht behoben sein.

Nach dem Starten der Transkription, stürzt Word ab.

Word stürzt ab, kaum wurde auf den Diktat Knopf gedrückt.

- Vergewissere Dich, dass **dein Mikrofon vom Add-in erkannt wird**, und funktionstauglich ist.
- Öffne den Taskmanager und schaue dir unter Leistung an, welche Komponenten deines Computers ausgelastet werden. Es kann sein, dass **zu viel Leistung von anderen Programmen** benötigt wird, und das Add-In nicht mehr in der Lage ist korrekt zu aufzunehmen und zu transkribieren.

Es dauert eine Weile, und der Computer fährt zu Höchstleistungen auf, bevor Word abstürzt.

Mit grosser Wahrscheinlichkeit ist **die Audio Chunk Mindestlänge zu kurz**. Ist diese kürzer als die Dauer, welche die Transkription eines Chunks benötigt, kann es auf schwächeren oder älteren Computern zu „Rückstau“ kommen. Das Add-In kommt also nicht mehr nach mit der Transkription, und der Computer ist irgendwann überlastet. **Versuche die «Minstdauer von Audioblöcken zu erhöhen**. Achte dich dabei im Taskmanager auf die Auslastung deiner GPU. Es sollten klar erkennbare Blöcke sichtbar sein. Ist die GPU konstant ausgelastet ist oben genannter Rückstau eingetreten.

Die Transkription ist fehlerhaft

Der eingefügte Text ist in der falschen Sprache.

- Überprüfe, dass die **Spracheinstellung und Mikrofonauswahl** korrekt sind.
- **Versuche ein anderes Mikrofon**. Whisper tendiert dazu bei schlechter Audioqualität, auf Englisch zu transkribieren.

- Werden russisch, französische oder sonstige Sprachen eingefügt, ist höchstwahrscheinlich der Umgebungslärm zu hoch, **probiere das Add-In an einem ruhigeren Platz.**

Es werden nur Interjektionen, Satzzeichen und Kauderwelsch eingefügt.

Bei schlechter Aufnahmequalität hat Whisper Mühe korrekte Transkriptionen zu erstellen. Die Qualität der Aufnahme wird durch viele Faktoren beeinflusst.

- Versuche die Einstellungen für **«Dauer der Stille zwischen Wörtern»** und **«minimale Dauer von Audioblöcken»** zu erhöhen.
- Versuche **lauter und deutlicher** zu sprechen.
- Versuche die **Entfernung von Mikrofon und Mund** anzupassen.
- Versuche ein **anderes Mikrofon** zu nutzen.
- Versuche **Hall und Umgebungsgespräche** zu reduzieren.

Jeweils am Anfang oder Ende eines eingefügten Textblocks ist die Transkription fehlerhaft

Die Aufnahme wird vom Programm geschnitten, wenn die Mindestdauer von Audioblöcken erreicht, und eine Pause zwischen Wörtern erkannt wurde. Funktioniert diese Erkennung von Pausen nicht richtig wird das Audio in der Mitte des Wortes geschnitten und es kommt zu fehlerhaften und halluzinierten Transkriptionen. **Versuche die «Dauer der Stille zwischen Wörtern» zu erhöhen.**

8. Impressum

Das ForensicWhisperDeskZH Add-in für Microsoft Office Word wurde vom ForMaLTec des Institutes für Rechtsmedizin im Auftrag und gemäss Anforderungen der FMB entwickelt.

Es handelt sich um ein OpenSource Tool mit MIT Lizenz, und kann gemäss dieser genutzt werden.



ForMaLTec
Forensic Machine Learning Technology Center